utb.

K. Wolfgang Kallus

Erstellung von Fragebogen

2. Auflage

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

UTB 4465

utb.
Lesen. Lernen. Punkten.

Eine Arbeitsgemeinschaft der Verlage

Böhlau Verlag · Wien · Köln · Weimar
Verlag Barbara Budrich · Opladen · Toronto
facultas.wuv · Wien
Wilhelm Fink · Paderborn
A. Francke Verlag · Tübingen
Haupt Verlag · Bern
Verlag Julius Klinkhardt · Bad Heilbrunn
Mohr Siebeck · Tübingen
Nomos Verlagsgesellschaft · Baden-Baden
Ernst Reinhardt Verlag · München · Basel
Ferdinand Schöningh · Paderborn
Eugen Ulmer Verlag · Stuttgart
UVK Verlagsgesellschaft · Konstanz, mit UVK/Lucius · München
Vandenhoeck & Ruprecht · Göttingen · Bristol
vdf Hochschulverlag AG an der ETH Zürich

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

K. Wolfgang Kallus

Erstellung von Fragebogen

2., aktualisierte und überarbeitete Auflage

facultas

K. Wolfgang Kallus, Univ.-Prof. Dr. rer. nat., Dr. phil. habil., lehrt an der Universität Graz am Institut für Psychologie. Er ist Leiter des Arbeitsbereichs für Arbeits-, Organisations- und Umweltpsychologie. Die konzeptgeleitete Entwicklung anwendungsorientierter Fragebogen und Messmethoden gehört seit vielen Jahren zu seinen Spezialbereichen in der Forschung und im von ihm geleiteten Institut für Begleitforschung.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Bibliografische Information der Deutschen Nationalbibliothek

Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über http://dnb.d-nb.de abrufbar.

Alle Angaben in diesem Fachbuch erfolgen trotz sorgfältiger Bearbeitung ohne Gewähr, eine Haftung des Autors oder des Verlages ist ausgeschlossen.

2., aktualisierte und überarbeitete Auflage 2016
Copyright © 2016 Facultas Verlags- und Buchhandels AG
facultas, Stolberggasse 26, 1050 Wien, Österreich
Alle Rechte, insbesondere das Recht der Vervielfältigung und der Verbreitung sowie der Übersetzung, sind vorbehalten.
Umschlagfoto: „sellingpix“ #20031421 / © Fotolia.com
Lektorat: Mag. Verena Hauser, Wien
Satz: Facultas Verlags- und Buchhandels AG
Einbandgestaltung: Atelier Reichert, Stuttgart
Druck und Bindung: CPI – Ebner & Spiegel, Ulm
Printed in Germany
ISBN: 978-3-8252-4465-1 Print
ISBN: 978-3-8385-4465-6 PDF

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Vorwort

„Wer dumm fragt" lautete der Arbeitstitel für diesen Leitfaden. Ebenso hätte man den Arbeitstitel auch freundlicher und nahe am Alltag von Fragebogen formulieren können: „Wer fragt, ohne sich genau überlegt zu haben, was er wissen will." Dieser Leitfaden zur Fragebogenentwicklung stellt das Ziel der Fragen in den Vordergrund oder anders gesagt die Klärung des Messanspruchs vor der Formulierung der Fragen. Im Unterschied zu einfachen, qualitativ orientierten Sammlungen von Fragen auf einem Papierbogen (Bogen mit Fragen) haben Fragebogen das Ziel, zuverlässig Merkmalsunterschiede zwischen Personen, Situationen oder Zuständen zu erfassen. Zu diesem Zweck müssen aufeinander abgestimmte Fragen entwickelt werden. Die Schritte hierzu werden in dieser Arbeit vorgestellt. Gut entwickelte Fragebogen sind leicht beantwortbar, eindeutig auswertbar und sprechen formal positiv an, d. h., sie sehen einfach aus. Dadurch entsteht immer wieder der Eindruck, dass die Entwicklung von Fragebogen keine Expertise voraussetzt und jede und jeder einen Fragebogen „mal schnell nebenher" entwickeln kann. Der Leitfaden versucht die grundlegende Expertise zu vermitteln und soll auch für NichtpsychologInnen verständlich sein. Eine grundlegende Expertise zur Messung von Verhaltens- und Erlebensmerkmalen wird jedoch vorausgesetzt – oder zumindest die Bereitschaft und die Grundausbildung, ein entsprechendes Lehrbuch bei der Fragenentwicklung zu Rate zu ziehen.

Bedanken möchte ich mich einerseits bei meinen akademischen Lehrerinnen und Lehrern, die nicht nur mein Interesse an den Methoden der Psychologie geweckt haben, sondern auch meine Motivation nachhaltig gefestigt haben, die Methoden der Psychologie immer möglichst optimal bei der Bearbeitung wissenschaftlicher und angewandter Fragestellungen einzusetzen. Dies hat auch dazu beigetragen, dass zwischenzeitlich die Entwicklung von Fragebogen neben anderen Methoden zu einem Standard in meinem Arbeitsbereich an der Karl-Franzens-Universität Graz werden konnte. Dank gebührt auch meinen Studierenden, die durch die „richtigen Fragen" und wiederholte Schwächen bei der Entwicklung von Fragebogen zum Entstehen dieses Büchleins beigetragen haben.

Auch dieser Leitfaden ist ähnlich wie ein Fragebogen immer noch optimierbar. Gute, sehr gute und exzellente Passagen hätten ihre Qualität in der ersten Auflage sicher nicht ohne die Expertise, konstruktive Kritik und die Vorschläge meiner Ehe-, Lebens- und Diskussionspartnerin Dipl.-Germ. Bärbel Kallus erreicht. Bei der Erstellung und Fertigstellung des Manuskripts der Erstform haben zudem Mag. Kerstin Käfer und Mag. Kerstin Eibel mitgewirkt. Die Bearbeitung der zweiten Auflage erhielt wesentliche Impulse von Mag. Elisabeth Dörner und Mag. Dr. Kerstin Gaisbachgrabner. Auch ihnen gebührt mein herzlicher Dank. Für die zweite Auflage wurden einige neuere Entwicklungen berücksichtigt, wie die Einordnung der Klassischen Testtheorie

in Messmodelle latenter Variablen, die zunehmende Bedeutung der Onlinebefragung, die wachsende Bedeutung der „Übersetzbarkeit“ von Fragebogen in mehrere Sprachen und die wachsende Rolle komplexer Auswertungen in linearen Strukturgleichungsmodellen.

Ein Buch wird auch heutzutage noch in seiner Leserfreundlichkeit und Struktur durch die LektorInnen des Verlags wesentlich mitgeprägt. Frau Mag. Dr. Sigrid Nindl und Frau Mag. Verena Hauser sei an dieser Stelle ebenfalls herzlich gedankt.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Inhaltsverzeichnis

Vorwort 5

1 Grundprobleme der Fragebogenkonstruktion 11

1.1 Einführung 11
1.2 Fragebogen als psychometrischer Test zur Erfassung eines Merkmalsbereiches 15
1.3 Merkmale und deren Definition aus der Perspektive der Befragten 17
1.4 Grundbausteine von Fragebogen: Items als Frage-Antwort-Einheiten 18
1.5 Messinformation von Fragebogen: Items, Subtest und Bereichssubtest 20

2 Ansätze zur Präzisierung und Operationalisierung des zu erfassenden Merkmalsbereiches 25

2.1 Adaptierung – Übersetzung – Neukomposition vorhandener Messinstrumente 26
2.1.1 Adaptierung – Übersetzung 26
2.1.2 Übernahme von Subtests und Items bei der Neukonzeption eines Fragebogens 27
2.2 Konzeptgeleitete Zusammenstellung von Subtests und Items 27
2.3 Interviews zur Präzisierung des Merkmalsbereiches 30
2.4 Workshop-Methoden 32
2.5 Empirisch basierte Konzeptdefinition 35
2.5.1 Faktorenanalytische vs. theoriegeleitete Subtestbildung 36
2.5.2 Faktorenanalysen auf Subtestebene 37
2.5.3 Grenzen der faktorenanalytischen Konzeptdefinition 38

3 Entwicklung der Items 41

3.1 Antwortformate und Antwortskalen 42
3.1.1 Formale Struktur der Antwortskala 43
3.1.2 Zustimmung und Zustimmungsurteile 46
3.1.3 Abgestufte Zustimmung 47
3.1.4 Intensitätsskalierung 48
3.1.5 Merkmalsbezogene Skalierungen 49
3.1.6 Polaritätenprofil – Semantisches Differential 51
3.1.7 Häufigkeitsskalen 52
3.1.8 Wahrscheinlichkeitsskalierung 53
3.1.9 Scoringsysteme 54

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

3.1.10 Verankerung von Urteilen ... 54
3.2 Antworttendenzen und systematische Messfehler ... 55
3.3 Formulierung des Frage-Aussage-Teils von Items ... 59
3.3.1 Semantisch-inhaltliche Aspekte: Einfachheit ... 59
3.3.2 Sprachliche Aspekte: die Sprache der Antwortenden ... 62
3.3.3 Psychologische Aspekte ... 67
3.3.4 Unabhängigkeit der Messfehler ... 71
3.4 Skalierung ... 71
3.4.1 Skalenniveau ... 72
3.4.2 Zulässige Transformationen und sinnvolle Statistiken ... 74
3.4.3 Skalenniveau von Fragebogenitems ... 76
3.4.4 Alternativen zur Klassischen Testtheorie ... 78

4 Schritte der Fragebogenentwicklung ... 79

4.1 Erstellung des Prototypen für den Fragebogen ... 79
4.1.1 Inhaltliche Prüfung der Subtests ... 81
4.1.2 Formale Prüfung der Subtests ... 82
4.1.3 Erstellung der Erstfassung ... 85
4.1.4 Deckblatt, Instruktionen und Studieninformationen ... 86
4.2 Entwicklung der Endform und Itemselektion ... 89
4.2.1 Pretest zur Beantwortung durch Zielpersonen ... 89
4.2.2 Entwicklungsstichprobe ... 90
4.2.3 Überprüfung von Subtests durch Itemanalyse ... 92
4.2.4 Itemselektion ... 93
4.2.5 Einbeziehung von Iteminterkorrelationen, Itemvaliditäten und -reliabilitäten ... 95

5 Endform(en) des Fragebogens und Auswertung ... 98

5.1 Kurzformen und Parallelformen ... 98
5.1.1 Erstellung von Kurzformen ... 98
5.1.2 Entwicklung von Parallelformen ... 99
5.2 Fragebogenvarianten ... 100
5.2.1 State-Trait-Ansätze ... 100
5.2.2 Situationsspezifische Fragebogen ... 101
5.2.3 Selbst-/Fremdbeurteilung ... 103
5.2.4 Fragebogenformen, -varianten und -systeme ... 104
5.2.5 Das Konzept des modularen Fragebogens ... 106
5.3 Fragebogenhandbuch: Dokumentation der Fragebogenentwicklung und Auswertungsleitlinie ... 108

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

5.3.1 Auswertungsbogen ... 108
5.3.2 Datenaufbereitung ... 109
5.4 Subtestprofile und Normen ... 110
5.4.1 Entwicklung einer Profildarstellung ... 111
5.4.2 Vergleichswerte und Normen ... 112

6 Qualität der Endform des Fragebogens ... 116

6.1 Fragebogen nach der Klassischen Testtheorie ... 116
6.2 Zuverlässigkeitskennwerte ... 118
6.2.1 Reliabilität und Änderungssensitivität ... 118
6.2.2 Wiederholungszuverlässigkeit von Fragebogen/Subtests ... 118
6.3 Validität ... 120
6.3.1 Systematische Verzerrungen ... 121
6.3.2 Soziale Validität ... 121
6.3.3 Augenscheinvalidität ... 122
6.3.4 Konstruktvalidität ... 123
6.3.5 Kriterienvaliditäten ... 124
6.3.6 Nützlichkeit und Ökonomie ... 125
6.4 Alternativen und Ergänzungen zur Klassischen Testtheorie ... 126
6.4.1 Probabilistische Testtheorie ... 127
6.4.2 Lineare Strukturgleichungsmodelle ... 128
6.4.3 Entscheidung zwischen unterschiedlichen testtheoretischen Ansätzen ... 130

7 Fragebogen in der Praxis ... 132

7.1 Fragebogen, Interview, Verhaltensbeobachtung ... 133
7.2 Prinzipien der Durchführung von Fragebogenerhebungen in der Arbeitswelt ... 134
7.2.1 Studienvorbereitung ... 135
7.2.2 Zusammenstellung von Fragebogen für Studien ... 136
7.2.3 Studiendurchführung ... 138
7.3 Rückmeldung von Ergebnissen ... 138
7.4 Ethische und juristische Rahmenbedingungen ... 141

8 Checklisten ... 143

9 Literatur ... 145

10 Glossar ... 151

11 Stichwortverzeichnis ... 157

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

1 Grundprobleme der Fragebogenkonstruktion

Ein Fragebogen ist ein psychometrisch entwickeltes Messverfahren, welches den Kriterien eines psychometrischen Tests so nahe wie möglich kommen soll. Ein Fragebogen liefert quantitative Informationen zur Beschreibung von aktuellen, vorübergehenden oder überdauernden Merkmalen von Personen oder Personengruppen (z. B. Teams). Fragebogen können sehr wohl aber auch zur Beschreibung von anderen Personen oder auch von Merkmalen der natürlichen, sozialen, kulturellen, erbauten und technischen Umwelt und der Arbeitswelt herangezogen werden. Ein psychometrischer Fragebogen grenzt sich ab von einer psychophysischen Skala, die eine physische Erscheinung (z. B. Schall oder Licht) im Hinblick auf eine Skalierungsdimension (z. B. Lautheit, Helligkeit) nach den Regeln der linearen oder der multidimensionalen Skalierung abbildet. Ein Fragebogen grenzt sich zudem von einfachen schriftlichen Befragungen ab, in denen mit Einzelfragen qualitative Informationen (z. B. Geschlecht) oder bereits metrisch vorliegende Informationen (z. B. Alter, Kinderzahl, Jahresbruttoeinkommen) erhoben werden wie bei soziologischen Datenerhebungen. Diese werden immer wieder unreflektiert mit Fragebogenfragen kombiniert.

1.1 Einführung

Die Grundlagen professioneller Fragebogenentwicklung werden trotz der inflationären Anwendung des Instruments „Fragebogen“ nur in den seltensten Fällen systematisch berücksichtigt. Selbst wissenschaftlich entwickelte Fragebogen beschränken sich oft allein auf statistische Verfahren, um erst im Nachhinein die gröbsten Schwachpunkte zu identifizieren. Im Gegensatz dazu stellt das vorliegende Buch die folgenden Überlegungen in den Mittelpunkt: „Was soll (eigentlich) erfragt und gemessen werden?“ und „Welche Fragen eignen sich dazu?“. Aus der systematischen Beantwortung dieser Kernfragen und mit der Umsetzung in Fragebogenfragen lässt sich in der Regel ein Messinstrument konstruieren, das auch bei einer statistischen Prüfung positive Ergebnisse erbringt.

Eine systematische Entwicklung von Fragebogen als Methode der Selbstbeschreibung oder auch der Fremdbeschreibung wird zunehmend wichtiger, da Befragungen, Interviews und die Teilnahme an statistischen Erhebungen zwischenzeitlich zu den alltäglichen Gegebenheiten unserer modernen Gesellschaft gehören. Befragungen erfreuen sich hoher Popularität und haben eine hohe Bedeutsamkeit erlangt – für gesellschaftliche, politische und wirtschaftliche Entscheidungen, für die Ausrichtung von Strategien in Unternehmen und Organisationen bis hin zu Investitionsentscheidungen. Auch bei der Erfolgskontrolle von gesellschaftlichen, wirtschaftlichen, politischen, pädagogischen, psychologischen Projekten und bei gesundheitsbezogenen

Maßnahmen spielen Fragebogen eine zunehmend wichtige Rolle. Und zudem stellen Fragebogen eine wesentliche Informationsquelle im Rahmen der Personalauswahl und -entwicklung, in der Psychodiagnostik, bei psychologischen Interventionen und in der Forschung dar. Dies betrifft nicht nur die Psychologie, sondern auch eine Vielzahl von Nachbardisziplinen. Ein Hintergrund für diese Entwicklung ist die wachsende Bedeutung der BürgerInnen als KonsumentInnen und Wirtschaftsfaktoren, der MitarbeiterInnen als „Sozialkapital des Unternehmens", der SchülerInnen, Studierenden und PatientInnen als „KundInnen". Diese Entwicklung trägt dazu bei, dass die Meinung, die Zufriedenheit oder der „Zustand" von Personen für EntscheidungsträgerInnen immer gewichtiger wird und damit eine Erhebung zuverlässiger Informationen notwendig scheint. In der Mehrzahl fällt die Wahl auf eine „Befragung" mittels Fragebogen. Selbst die moderne Qualitätssicherung baut auf Befragungen, da die Qualität von Produkten durch das NutzerInnenurteil mitdefiniert wird.

Die herausragende Bedeutung von standardisierten Befragungen bis hin zur Qualitätssicherung von Dienstleistungen und Produkten bildet den Ausgangspunkt dieses Buches, das seinerseits der Frage nach der Qualität von Befragungsinstrumenten, insbesondere von Fragebogen, nachgeht. Die Zielsetzung lässt sich zusammenfassend so formulieren: Einsatz von Fragebogen statt Bogen mit Fragen. Im Zentrum steht dabei die Fragestellung, wie vorzugehen ist, um die benötigte Information zu erhalten. Dieser Ansatz geht weit über die bisher vorliegenden Arbeiten hinaus, die sich den Themen „Wie formuliere ich Fragen?", „Welche Antwortformate stehen zur Verfügung?" und „Wie vermeide ich Verzerrungen in den Antworten durch soziale Erwünschtheit?" widmen.

Selbstverständlich ist es immer möglich, eine Befragung durchzuführen, die Aussagen enthält wie „Ich bin mit meiner Arbeit unzufrieden" , „Ich habe Angst", „Mein Unternehmen finde ich gut", „Ich bin ein guter Mitarbeiter/eine gute Mitarbeiterin" mit den Antwortskalen „trifft nicht zu" bis „trifft völlig zu" oder „ja/nein". Diese Aussagen und ihre Antworten erfassen jedoch nicht systematisch ein Konzept, sondern bieten lediglich grobe Anhaltspunkte für Entscheidungen. Weder die Frage nach der Zuverlässigkeit dieser qualitativ zu interpretierenden Informationen noch die Frage, ob tatsächlich das gewünschte Merkmal gemessen wird, lassen sich ohne weitere Zusatzinformationen beantworten: Unkontrollierte Urteilsfehler, Antworttendenzen, die Tendenz zur sozialen Erwünschtheit, Suggestiveffekte, Stimmungseffekte aufgrund des aktuellen Tagesgeschehens und vieles mehr mindern die Qualität der „Bogen mit Fragen". Diese „Bogen mit Fragen" begegnen uns in einem breiten Spektrum von Medien und in vielen Lebensbereichen. Die Palette umfasst die sog. „Psychotests" in den Printmedien und im Internet, Volksbefragungen, KundInnenbefragungen, MitarbeiterInnenbefragungen, standardisierte Befragungen in der Markt- und Meinungsforschung. Selbst in Forschungsarbeiten aus Psychologie, Soziologie, Pädagogik, Politikwissenschaft, Betriebswirtschaft, den Umweltwissenschaften, den Kommunikations-

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

und Medienwissenschaften sowie modernen Teildisziplinen wie der Pflegewissenschaft und den Gesundheitswissenschaften kommen oft Bogen mit Fragen statt Fragebogen zum Einsatz.

Anstelle der oberflächlichen Abfrage von augenscheinlich wichtigen Themen **bezieht sich der aussagekräftige Fragebogen auf ein klar definiertes Konzept**. Eine Befragung zur PatientInnenzufriedenheit kommt deshalb nicht umhin, sich auch mit der folgenden Frage zu befassen: „Was ist Zufriedenheit und was ist Unzufriedenheit?" Ein Blick in ein psychologisches Lehrbuch zeigt, dass Zufriedenheit die Bewertung eines oder mehrerer Ergebnisse oder Prozesse in Abhängigkeit von den Erwartungen darstellt. Die Erwartungen wiederum sind durch die Kosten für das Individuum mitbestimmt. Setzt man diese Überlegungen fort, schlüsselt sich die PatientInnenzufriedenheit in Zufriedenheit mit unterschiedlichen Facetten der Behandlung und des Genesungsprozesses auf. Gleichzeitig wird die zentrale Bedeutung von Erwartungen sichtbar und es kommt der Gedanke auf, dass Zufriedenheit, fehlende Zufriedenheit und Unzufriedenheit nicht unbedingt auf einer „Dimension" liegen.

Kriterien zur Bewertung der Instrumente und Hinweise zur professionellen Gestaltung von Fragebogen fehlen uns jedoch in den meisten Fällen oder decken nur unvollständig und theoriefern Teilaspekte ab (Porst, 2009). Die Lektüre dieses Leitfadens soll die LeserInnen in die Lage versetzen, die Unterscheidung zwischen einem „Bogen mit Fragen" und einem „Fragebogen" nachzuvollziehen und eine Bewertung der „Angebote" im Spektrum zwischen spielerischem Medienquiz, Instrument zur Sammlung qualitativer und semiquantitativer Information bis hin zum Testverfahren mit diagnostischem Potenzial vorzunehmen. Den EntwicklerInnen von Befragungsinstrumenten sollen die wichtigsten Regeln für die Konstruktion eines guten Fragebogens vermittelt werden. Außerdem erfahren sie Unterstützung bei der Entscheidung, ob für die Entwicklung oder die Gestaltung eines Instruments zur KundInnenzufriedenheit oder MitarbeiterInnenzufriedenheit ExpertInnen hinzuzuziehen sind, damit in reproduzierbarer Weise hinreichend gehaltvolle Informationen über ein definiertes Konzept erfasst werden. Für die Berufsgruppe der PsychologInnen soll dieser Leitfaden die Kenntnisse der statistischen Modelle zur Fragebogen- und Testkonstruktion inhaltlich und formal ergänzen und dazu beitragen, eine effiziente und professionelle Fertigkeit zur Fragebogenkonstruktion zu entwickeln. Die Mehrzahl der beschriebenen Vorgehensweisen lassen sich in analoger Weise auf die Konstruktion von Beobachtungssystemen übertragen.

Ein Kernpunkt in diesem Buch betrifft die **Operationalisierung eines Merkmalsbereiches durch (selbst)beobachtbare Indikatoren und die Umsetzung dieser Indikatoren in Gruppen leicht beantwortbarer Frage-Antwort-Einheiten**. Dieser Ansatz wird bislang im Hinblick auf die Fragebogenentwicklung gar nicht oder nur am Rande behandelt. Anhand von Beispielen wird erläutert, dass ein Fragebogen nicht aus beliebigen Fragen bestehen sollte, sondern aus Gruppen von Frage-Antwort-Einheiten

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

(sog. Items), die einem Merkmalsbereich oder Konzept zuzuordnen sind. Dabei wird eine Reihe von Grundregeln zur Formulierung von Items vorgestellt. Diese Regeln modifizieren einige althergebrachte Prinzipien, die ursprünglich eingeführt wurden, um Antworttendenzen zu vermeiden. Im zweiten Teil werden die Zusammenstellung von Items zu einem Fragebogen und die Prüfung der Fragebogengüte behandelt. In diesem zentralen Kapitel zur Fragebogenentwicklung steht die Beziehung zwischen inhaltlichen und statistischen Konzepten im Vordergrund. Dabei werden wiederholt die Grenzen der oft verabsolutierten statistischen Kenngrößen und Analyseprinzipien thematisiert und eine inhaltlich geleitete Vorgehensweise vorgeschlagen, die die statistischen Methoden als Werkzeug in ihren Dienst stellt. Im Anschluss daran werden Regeln zur Entwicklung und Prüfung der Endform des Fragebogens an Beispielen illustriert. In den letzten Abschnitten werden Fragebogen und Interview mit ihren jeweiligen Einsatzbereichen abgegrenzt sowie die Bedingungen zur Durchführung und Rückmeldung von Fragebogenerhebungen und MitarbeiterInnenbefragungen einschließlich ethischer und juristischer Aspekte diskutiert. Beispiele und Checklisten am Ende des Buches dienen der Erläuterung und Handhabbarkeit der Prinzipien und Methoden.

Die Mehrzahl der bisher vorliegenden Arbeiten zur Testkonstruktion stellt den mathematisch-statistischen Hintergrund verschiedener testtheoretischer Modelle in den Vordergrund (Böttcher, 2007; Bühner, 2011; Eid & Schmidt, 2014; Kranz, 2001; Krauth, 1995; Kubinger, 1989; Lienert & Raatz, 1998; Moosbrugger & Kelava, 2007; Rost, 2004). Arbeiten mit einem überwiegend inhaltlichen Bezug sind von Mummendey (1987) und Osterlind (1989) publiziert worden. Mummendey geht vor allem auf den Fragebogen als Forschungswerkzeug ein und beschränkt sich dabei auf Beispiele zur einstellungsorientierten Messung mit Zustimmungsskalen. Osterlind leistet in seinem englischsprachigen Werk für die Leistungs- und Kenntnismessung Ähnliches wie die vorliegende Arbeit für die Messung von Merkmalen mittels Fragebogen, die Osterlind im Vorwort explizit ausklammert. Wertvolle Tipps und Anhaltspunkte entstammen auch Arbeiten aus der empirischen Sozialforschung. In diesen Arbeiten liegt der Schwerpunkt jedoch bei Einzelfragen (Porst, 2009), nicht jedoch bei der Entwicklung von konzeptbezogenen Frage-Antwort-Gruppen, die ein psychometrisches Verfahren kennzeichnen.

Für die **Entwicklung eines Fragebogens sind folgende Schritte** abzuarbeiten:

1. Abgrenzung und Klärung des zu erfassenden Merkmalsbereiches und der Zielpopulation. Bei der Festlegung der Zielpopulation ist auch an mögliche Vergleichsgruppen, „Benchmarks“ und Weiterentwicklungen zu denken. Daher gilt die Regel für die Festlegung der Zielpopulation: Eher breit definieren!
2. Spezifizierung des Merkmalsbereiches und Sammlung von Beispielen. Hier sollten möglichst umfassend Verhaltensweisen, Leistungen, Manifestationen in Gedanken, Gefühlen, Motivationen, Wünschen, Symptomen und Zuständen körperlicher und psychischer Art aufgelistet/gesammelt werden. Zur Unterstützung werden in dieser

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Phase häufig Interviews, Verhaltensbeobachtung, Arbeitsanalysen, Unfallanalysen und Dokumentenanalysen oder auch Workshops mit ExpertInnen eingesetzt.
3. Gruppierung der Manifestationen in Teilbereiche, die in ähnlicher Weise mit unterschiedlichen Merkmalsausprägungen variieren
4. Festlegung der charakteristischen Manifestationsvariation und Festlegung der Antwortdimensionen
5. Formulierung der Items
6. Prüfung der Items auf sprachliche Konsistenz, Einfachheit und Verständlichkeit
7. Festlegung von Instruktionen, Ankern und Vorgabemodalitäten
8. Fixierung der Itemreihenfolge
9. Durchführung einer Studie zur Prüfung der Subtests/Items
10. Kürzung/Ergänzung des Fragebogens
11. Festlegung von Varianten des Fragebogens
12. Normierung und Auswertungsrichtlinien
13. Validierung und Interpretationsrichtlinien

Mit den 13 Schritten der Fragebogenentwicklung entsteht ein psychometrisch geprüfter Fragebogen mit definierter Qualität, der auch in Normensystemen (z. B. ISO 10075 oder DIN 33430) eingeordnet werden kann. Während ein „Bogen mit Fragen" z. T. wenig zuverlässige qualitative Informationen liefert, sind mit psychometrisch geprüften Fragebogen exakte Messungen von Veränderungen der Merkmalsausprägung oder von Unterschieden zwischen Personen, Gruppen, Teams oder Organisationseinheiten möglich.

1.2 Fragebogen als psychometrischer Test zur Erfassung eines Merkmalsbereiches

Mit der Unterscheidung zwischen Fragebogen als psychometrisch geprüftem Messinstrument für quantitative Aussagen zu einem definierten Merkmalsbereich und der Vorgabe von Fragen zur späteren qualitativen Analyse („Bogen mit Fragen") wird ein Fragebogen als Test im Sinne der klassischen Arbeit „Testaufbau und Testanalyse" von G. A. Lienert (1969) klassifiziert. Danach ist ein Test ein „wissenschaftliches Routineverfahren zur Untersuchung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale mit dem Ziel einer möglichst quantitativen Aussage über den relativen Grad der individuellen Merkmalsausprägung" (Lienert, 1969, S. 7). Die Vorgabe von Fragen zur qualitativen Analyse wird im Kapitel 7.1 „Fragebogen, Interview, Verhaltensbeobachtung" aufgegriffen.

Ein Fragebogen versucht, den Kriterien für einen psychometrischen Test zu entsprechen und den zu erfassenden Merkmalsbereich möglichst objektiv, zuverlässig und valide abzubilden.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

- **Objektivität** im Sinne von Intersubjektivität erlaubt, die Merkmale unabhängig von den UntersuchungsleiterInnen zu erfassen. Objektivität bezieht sich dabei auf die Durchführung der Befragung, die Auswertung der Daten und die Interpretation der Ergebnisse.
- **Zuverlässigkeit** lässt sich erzielen, wenn die Fragen so gestellt werden, dass die antwortenden Personen in konsistenter Weise antworten können und die Ergebnisse sich bei unterschiedlichen Fragen zu einer Merkmalsfacette in vergleichbarer Weise zeigen. Konsistente Antworten schlagen sich in hohen Kennwerten für die Zuverlässigkeit (Reliabilität) des Fragbogens nieder. Zur Reliabilitätsprüfung werden Parallelmessungen und/oder Messwiederholungen vorgenommen. Parallelmessungen erfolgen zum Beispiel, wenn jede Merkmalsfacette durch mehrere Fragen abgebildet wird. Messwiederholungen finden abhängig von der Stabilität des zu messenden Merkmals nach kurzem oder längerem Zeitintervall statt. Die unterschiedlichen Optionen der Reliabilitätsschätzung werden im Kapitel 6.2 zur Überprüfung der Güte von Fragebogen diskutiert.
- Schließlich soll der Merkmalsbereich **valide** (modellkonform) abgebildet werden. Der Fragebogen soll diejenigen Merkmale und Zustände abbilden, die er zu messen vorgibt. Validität lässt sich insbesondere durch eine möglichst präzise Festlegung des zu messenden Merkmalsbereiches im Rahmen der Fragebogenentwicklung erreichen.

Die Definition des Merkmalsbereiches und seine Operationalisierung stellen einen zentralen Schritt in der Fragebogenentwicklung dar, dem in diesem Buch besondere Aufmerksamkeit geschenkt wird. Ziel der operationalen Definition ist eine Umschreibung der Äußerungsformen von Merkmalsunterschieden. Die Frage, wie sich inter- und intraindividuelle Unterschiede in der Merkmalsausprägung aus Sicht der Befragten darstellen und optimal operationalisieren lassen, stellt den zentralen ersten Schritt bei der Erstellung der Fragebogengrundeinheiten dar: die Formulierung der Items.

Die Operationalisierung des Merkmalsbereiches aus Sicht der Befragten bildet den ersten zentralen Schritt zur Sicherung der Validität (Gültigkeit) der Messungen. Selbstverständlich ist die Validität durch ergänzende empirische Daten – wie die Korrelationen zu relevanten Kriterien oder verwandten Konzepten – zu bestätigen. Hohe Validitätskoeffizienten können aber auch durch triviale Zusammenhänge oder durch Scheinkorrelationen, bedingt durch Drittvariablen, entstehen. Auch dieses Problemfeld wird in einem eigenen Abschnitt diskutiert (Kapitel 6.3). Dabei wird insbesondere das Problem der Augenscheinvalidität kritisch beleuchtet. Augenscheinvalidität ist sowohl ein Problem bei der Itemformulierung und -auswahl als auch ein Problem bei der Interpretation von Fragebogenergebnissen. Ein verbreiteter Interpretationsfehler betrifft die absolute Interpretation der erhaltenen Skalenwerte, z. B. für Arbeitszufriedenheit. Ohne Vergleichswerte verbietet sich die absolute Interpretation der Mess-

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

werte für ein psychometrisches Testverfahren, das maximal Intervallskalenniveau aufweist.

Die statistische Überprüfung der Testgüte kann mittels Klassischer Testtheorie (Lienert & Raatz, 1998; Lord & Novick, 1968), anhand der Generalisierbarkeitstheorie von Cronbach, Gleser, Nanda und Rajaratnam (1972), anhand moderner statistischer Analysen mit linearen Strukturgleichungsmodellen (Steyer & Eid, 2001) oder auch mit einer Analyse in einem probabilistischen Testmodell (Fischer, 1974) erfolgen. Auch wenn die psychometrische Testkonstruktion im klassischen Modell erfolgt und dementsprechend die Frage der Messung im engeren Sinn außen vor bleibt, kann durch die Auseinandersetzung mit der Frage nach den zu messenden Merkmalen oder Konzepten ein wesentlicher theoretischer und praktischer Gewinn resultieren. Das Verständnis für die inhaltlich notwendigen Schritte bei der Fragebogenkonstruktion hilft, psychometrisch aussagekräftige, zuverlässige Ergebnisse zu erzielen.

1.3 Merkmale und deren Definition aus der Perspektive der Befragten

Die Definition der zu erfassenden Merkmale und dafür repräsentativer persönlicher Reaktionen und Zustände, in denen sich Unterschiede im zu erfassenden Merkmalsbereich niederschlagen, stellt die Basis für eine effiziente und professionelle Entwicklung eines Fragebogens dar (Cronbach, Gleser, Nanda & Rayaratnam, 1972; Osterlind, 1989). Dieser erste wichtige Schritt wird jedoch nur von wenigen EntwicklerInnen mit der notwendigen Aufmerksamkeit und Konsequenz verfolgt.

Das Ergebnis der Operationalisierung aus der Perspektive der Befragten muss eine klare Abgrenzung und Kennzeichnung der zu messenden Konzepte und Merkmale sein. Die Operationalisierung erfolgt aus der Perspektive der Befragten. Dies meint nicht, dass die Operationalisierung auf der Ebene des Alltagsverständnisses der Befragten stehen bleibt. Psychologische Konzepte müssen aber aus der Sicht der Befragten (re)formuliert werden. Dabei ist zu klären, in welchen Ereignissen, Verhaltensweisen, persönlichen Zuständen oder auch Kognitionen sich unterschiedliche Ausprägungen des Merkmals niederschlagen. Ausgehend von einer hinreichend klaren Vorstellung über das zu messende Merkmal und die hierfür relevanten psychologischen Konzepte lassen sich die möglichen Manifestationen als Basis für die Formulierung von Items ableiten. Die möglichst klare und valide Operationalisierung der Merkmale muss immer die Frage beantworten, wie sich unterschiedliche Merkmalsausprägungen aus Sicht der Befragten darstellen und wie sie sich aus Sicht der Befragten kennzeichnen lassen. Die Übernahme der Perspektive von Befragten, von KundInnen, MitarbeiterInnen, PatientInnen und StudienteilnehmerInnen ist zentral für die angemessene und zielorientierte Formulierung von Items.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Fragen sollten sich möglichst konkret auf Aspekte beziehen, die für die Befragten sichtbar, spürbar, erlebbar und erfahrbar sind. Wenn sich Fragen auf abstrakte, vorgestellte und generalisierte Gegenstände beziehen, lassen die Ergebnisse der Befragung nur selten konkrete Vorhersagen zu und die Antworten können durch Faktoren wie eine positive Selbstdarstellungstendenz, soziale Erwünschtheit oder Antworttendenzen stark verzerrt werden. Fragen wie „Sind Sie ein zuverlässiger Mensch?“ oder „Sind Sie ein guter Autofahrer?“ erbringen deutlich mehr Ja-Antworten als aufgrund der Anzahl zuverlässiger Menschen oder guter AutofahrerInnen in der Population zu erwarten sind.

Auf der anderen Seite treffen sehr spezifische Fragen nur auf einen Teil der Personen oder nur sehr selten zu. Fragen zu seltenen Ereignissen sind für die Mehrzahl der Befragten nicht relevant und differenzieren daher oft nicht. Beispiele sind: „Ich bin in den letzten Tagen mit Unverschämtheiten am Arbeitsplatz konfrontiert worden“ oder „Ich habe im letzten halben Jahr ein große Geldsumme gewonnen“.

Fragebogen sind sowohl zur Selbst- als auch zur Fremdbeschreibung oder auch zur Selbst- und Fremdbeurteilung einsetzbar. Fragebogen können sich auf unterschiedliche Merkmalsbereiche beziehen und sind nicht auf die Messung von psychischen Merkmalen wie Emotion oder Persönlichkeitsmerkmalen beschränkt. Beispielsweise kann eine Symptomliste auch physiologische Zustände abbilden (Mehrdimensionale körperliche Symptomliste; Erdmann & Janke, 1978), ein Beschreibungsinstrument wie das „Semantische Differential“ Umweltaspekte aus Sicht der NutzerInnen widerspiegeln (Mehrabian & Russell, 1974) und ein Fragebogen wie das „Instrument zur Stressbezogenen Arbeitsanalyse“ (ISTA; Semmer, Zapf & Dunckel, 1999) Arbeitssituationen aus Sicht der Arbeitstätigen oder auch aus Sicht von ExpertInnen charakterisieren.

Wichtig ist, dass ein Item für die Bezugspopulation **eindeutig beantwortbar** ist. Dies bedeutet nicht, dass Items für jede Bezugsgruppe anders zu formulieren sind, vielmehr sind zu spezifische Formulierungen zu vermeiden, um Vergleichbarkeit zu erhalten. Dieses scheinbare Dilemma wird in Kapitel 5.2.5 unter dem Stichwort „modulare Fragebogen“ diskutiert und gelöst.

Als Leitfaden gilt, für den Merkmalsbereich spezifische Fragen zu finden, die in Häufigkeit und/oder Intensität für alle Befragten relevant sind. Dabei ist zu berücksichtigen, dass bei der Entwicklung von Items für einen Fragebogen nicht allein die Fragen, sondern auch die zugehörigen Antwortkategorien eine entscheidende Rolle spielen.

1.4 Grundbausteine von Fragebogen: Items als Frage-Antwort-Einheiten

Ein Fragebogen besteht aus systematisch zusammengestellten Frage-Antwort-Einheiten. Diese Frage/Feststellung-Antwort-Kombinationen werden mit dem Begriff Frage-

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

bogenitem oder kurz Item bezeichnet. Dabei werden mehrere Fragen mit einem identischen Antwortmodus vorgegeben, d. h., der Fragebogen besteht aus mehreren Items mit identischem Antwortformat. Im Abschnitt über die Formulierung von Items wird ausführlich diskutiert, dass das Antwortformat zur Frage/Feststellung passen sollte und unterschiedliche Antwortformate zur selben Frage unterschiedliche Aussagen ergeben können.

Items sind für die Beantwortenden eindeutig und klar zu formulieren. Subjektiv zu interpretierende Elemente, einseitige, suggestive oder für Personengruppen benachteiligende Formulierungen sind ebenso zu vermeiden wie Mehrdeutigkeiten. Im Idealfall entsprechen die Items dem Merkmal in repräsentativer Weise. Mit dem Perspektivenwechsel, dass es viele Antworten gibt und die dazu richtigen Fragen zu finden das eigentliche Problem darstellt, macht Michael Ende in der „Unendlichen Geschichte" (Ende, 1979) auf das Problem der Passung zwischen Fragen und Antworten aufmerksam. Bei der Fragebogenentwicklung wird der Schwerpunkt in der Regel auf die angemessenen Fragen gelegt, ohne dabei die Antwortoptionen angemessen zu betrachten. Die Antwortoptionen sind aber oft entscheidend für treffsichere Fragen.

Mögliche Unterschiede lassen sich an der Frage „Haben Sie Kopfweh?" verdeutlichen (Box 1).

Box 1: Unterschiedliche Antwortmodi zur selben Aussage

A
Ich habe Kopfweh.

0	1	2	3	4	5	6
trifft überhaupt nicht zu	trifft nicht zu	trifft eher nicht zu	weder/ noch	trifft eher zu	trifft zu	trifft voll und ganz zu

B
Ich habe Kopfweh.

0	1	2	3	4	5	6
gar nicht	sehr schwach	schwach	etwas	ziemlich	stark	sehr stark

C
Ich habe Kopfweh.

0	1	2	3	4	5	6
nie	selten	manchmal	mehrmals	oft	sehr oft	immerzu

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Die unterschiedlichen Antwortmodi beleuchten unterschiedliche Facetten des Kopfschmerzproblems. Die erste Antwort lässt eine eher undifferenzierte Aussage zu und trifft wahrscheinlich eher aktuelle Kopfschmerzen, z. B. bei einer Befragung zu kritischem Raumklima oder beim „Sick-Building-Syndrom". Der zweite Antwortmodus beantwortet die Intensitätsfrage, während die dritte Möglichkeit eher bei chronischen Kopfschmerzproblemen zu hohen Werten führt.

Bei den Antwortmöglichkeiten kann es sich im Falle von gebundenen Antwortformaten auch um qualitative Kategorien handeln (z. B. ja/nein), um geordnete Kategorien („gar nicht", „wenig", „etwas", „viel", „sehr viel"; vgl. Kallus & Krauth, 1995; Krauth, 1995), um eine metrische Skalierung oder auch um eine kontinuierliche Skala. Das Problem der Skala/Skalierung wird in Kapitel 3.4 ausführlich diskutiert.

Anmerkung: Interessanterweise ist die Mehrzahl der Items in „Fragebogen" eher als Aussage mit Selbst-/Fremdbeschreibung und mit entsprechenden Antwortoptionen, aber nicht als explizite Frage formuliert.

1.5 Messinformation von Fragebogen: Items, Subtest und Bereichssubtest

Ziel eines psychometrischen Fragebogens ist es, unterschiedliche Merkmalsausprägungen von Eigenschaften, Einstellungen und Meinungen, Bewertungen, Verhaltenstendenzen, Zuständen oder längerfristigen Reaktions- oder Stimmungslagen bei Personen oder Personengruppen repräsentativ zu erfassen und zahlenmäßig wiederzugeben. Dabei kann es sich um Unterschiede im Zeitverlauf (Veränderungen) handeln oder um Unterschiede zwischen Personen oder Personengruppen.

Zu diesem Zweck werden bei einem Fragebogen die Werte für zusammengehörige Items zu einem Messwert, dem Subtestwert, verrechnet. Diese Zusammenfassung von Items zu einem sog. **Subtest** bildet die Grundlage, um die Güte der Fragen mit den Verfahren der Klassischen Testtheorie (Lord & Novick, 1968) zu analysieren. In der Regel umfasst ein Fragebogen mehrere Subtests, um einen Merkmalsbereich in seinen unterschiedlichen Facetten abzubilden. Jeder Subtest entspricht einer Facette des Merkmals. Das Konzept der Subtests stellt den Unterschied des „Bogens mit Fragen" zum psychometrischen Fragebogen her.

Den Antworten werden bei jedem Item für die Auswertung Zahlen zugeordnet. Rein technisch werden bei zahlenmäßig vorgegebenen Antworten die Zahlenvorgaben der Antworten gewählt. Diese Konvention ist jedoch messtheoretisch nicht zwingend, da bei einer Intervallskala und natürlich auch bei einer Rangskala die Zahlenzuordnung weit beliebiger ist (vgl. Kap. 3.4). Bei der Auswertung und der Bestimmung der Güte eines Fragebogens geht der Untersuchende explizit oder implizit von den Grund-

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

annahmen („Axiomen") der Klassischen Testtheorie aus. Die Axiome der Klassischen Testtheorie sind in Abbildung 1 dargestellt. Diese sind/lauten:

- Messwert x: Dieser wird additiv in den wahren Wert t und den Messfehler e zerlegt (x = t+e).
- Messfehler und wahrer Wert sind unabhängig.
- Messfehler zweier Items sind unabhängig.

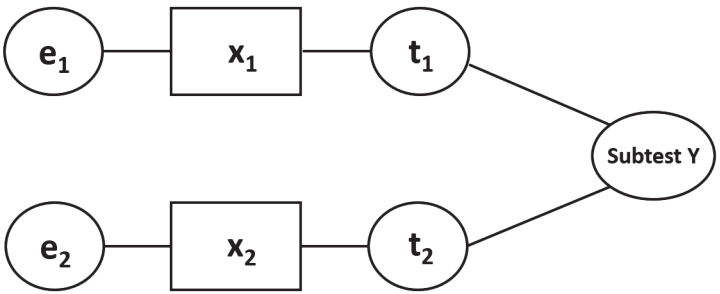

Abbildung 1: Axiome der Klassischen Testtheorie (Kallus, 2016)

Die Axiome der Klassischen Testtheorie in Abbildung 1 fassen die Annahmen für zwei Items grafisch in Anlehnung an Steyr und Eid (2001) zusammen. Der aus der Antwort bestimmte Messwert eines Items zerfällt in Fehler und wahren Wert. Ein Subtest besteht aus zwei oder mehr Items, die jeweils eine wichtige Facette des zu messenden Merkmals (z.B. Prüfungsangst) beitragen. Abbildung 1 verdeutlicht, dass weder die Messfehler (z.B. durch unklare Itemformulierungen) mit dem wahren Wert zu tun haben noch untereinander abhängig sein dürfen (z.B. durch komplexe Syntax oder doppelte Verneinungen in beiden Fragen).

In manchen Messmodellen wird ein Teil der Antworten bei einem Item zusätzlich einem spezifischen Anteil zugeschrieben, der zwar zuverlässig erfasst wird, aber nichts Gemeinsames mit allen anderen Items des Subtests hat. Diese spezifische Arbeit wird jedoch in den meisten Auswertungsmodellen nicht berücksichtigt (vgl. Steyr & Eid, 2001; Eid & Schmidt, 2014).

Eine grafische Darstellung für den Subtest „Allgemeine Beanspruchung" des Erholungs-Belastungs-Fragebogens (EBF; Kallus, 1995, 2016) zeigt Abbildung 2. Dieser Fragebogen bildet den gegenwärtigen Beanspruchungs-/Erholungszustand einer Person ab. Die Subtests des EBF in der Form mit 48 Items bestehen aus je vier Items. Jedes Item wird zerlegt in Messfehler und den wahren Wert, wobei spezifische Varianzanteile dem Fehler zugerechnet sind. Die Zahlen an den Pfeilen in Abbildung 2 verdeutlichen die Gewichte, mit denen die Items zum Subtest „Allgemeine Beanspruchung" beitragen. Bei der Prüfung dieses Modells durch die statistische Prozedur der „linearen

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Strukturgleichungsmodelle“ ergab sich ein gutes Ergebnis. Zusammenfassend kann festgehalten werden, dass ein Subtestwert durch die additiv zusammengefassten Werte von mindestens zwei Items gebildet wird.

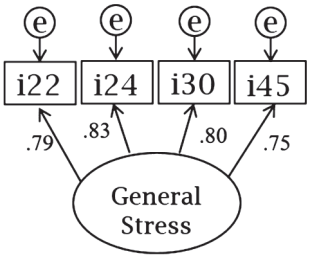

Abbildung 2: Messmodell für „Allgemeine Beanspruchung“ (Kallus, 2016, S. 66)

Ein Fragebogen wie der EBF umfasst in der Regel mehrere solcher Subtests. Für den EBF wird „Beanspruchung“ theoriegeleitet in Anlehnung an die Klassifikationen von Stress nach Janke (1976) in insgesamt sieben Facetten (Subtests) abgebildet. Die Gesamtheit der Subtests soll den zu messenden Merkmalsbereich über Feststellungen oder Fragen in einem Profil oder Gesamtwert angemessen zahlenmäßig repräsentieren. „Erholung“ umfasst insgesamt fünf Subtests. Alle zwölf Subtests werden in der Regel gemeinsam betrachtet und in einem grafischen Subtestprofil zusammengefasst. Ein Profil lässt sich darstellen, indem die Subtestwerte einer Person oder einer Gruppe in ein Profilschema eingetragen und diese Werte verbunden werden. Details zur Darstellung und Interpretation von Fragebogenprofilen werden in Kapitel 5.4 besprochen.

Tabelle 1: Subtests des Erholungs-Belastungs-Fragebogens (EBF-Basic)

Subtest (Itemzahl)	Bezeichnung (Abkürzung)
1 (k=4)	Allgemeine Beanspruchung – Niedergeschlagenheit (BEA-ALLG)
2 (k=4)	Emotionale Beanspruchung (BEA-EMO)
3 (k=4)	Soziale Spannungen (BEA-SOZ)
4 (k=4)	Ungelöste Konflikte – Erfolglosigkeit (KONFL)
5 (k=4)	Übermüdung – Zeitdruck (ÜMÜDG)
6 (k=4)	Energielosigkeit – Unkonzentriertheit (ENLOS)
7 (k=4)	Körperliche Beschwerden (BEA-SOM)
8 (k=4)	Erfolg – Leistungsfähigkeit (ERFOLG)
9 (k=4)	Erholung im sozialen Bereich (ERH-SOZ)
10 (k=4)	Körperliche Erholung (ERH-SOM)
11 (k=4)	Allgemeine Erholung – Wohlbefinden (ERH-ALLG)
12 (k=4)	Erholsamer Schlaf (SCHLAF)

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Wenn aus Gründen der Vereinfachung auf die Detailinformation aus den Subtests verzichtet werden soll, ist es möglich, Facetten des Merkmals zusammenzufassen und übergeordnete Werte zu bilden. Die in einen Bereich gehörenden Subtests werden dann zu Bereichssubtests zusammengefasst. Auf diese Weise kann aus dem Erholungs-Belastungs-Fragebogen ein sinnvoller Gesamtwert für sozial-emotionale Beanspruchung gebildet werden. Die Struktur dieses Subtests zeigt Abbildung 3. Für die übergeordneten Werte soll im Folgenden der Begriff des **Bereichssubtests** verwendet werden. (*Anmerkung:* Bei älteren Fragebogenverfahren wurde in Anlehnung an den angloamerikanischen Sprachgebrauch der Begriff **„Skala"** auch alternativ zum Subtestbegriff benutzt. Der Begriff Skala wird in dieser Arbeit nur zur Bezeichnung der Antwortformate verwendet, z. B. „Intensitätsskala". Diese Festlegung ist mit der Begriffswelt der linearen Skalierung kompatibel, da bereits auf Itemebene eine erste zahlenmäßige Repräsentation von Merkmalsunterschieden stattfindet.)

Statistisch wird die Frage, ob Items zu einem Bereich gehören und ob es sinnvoll ist, Subtests zu einem Bereich zusammenzufassen, auf Basis von Kovarianzen bzw. Korrelationen entschieden. Korrelationen bilden die linearen Zusammenhänge zwischen den Items (oder Subtests) ab. Eine Vielzahl von paarweisen Korrelationen (d. h. die Korrelationsmatrix) kann schnell sehr unübersichtlich werden. Als einfache Methode zur Strukturierung von Korrelationsmatrizen hat sich die sog. Faktorenanalyse etabliert. Die Faktorenanalyse sucht nach voneinander relativ unabhängigen Gruppierungsvariablen, zu denen sich die zum Faktor gehörenden Variablen zusammenfassen lassen. So bilden beispielsweise Erholung und Beanspruchung in Faktorenanalysen bei unterschiedlichen Stichproben immer wieder zwei (relativ unabhängige) Faktoren.

Aus diesem Grund ist eine weitere Zusammenfassung zu einem Gesamtwert nicht sinnvoll, sondern der aktuelle Zustand der Person lässt sich nur über eine Kombination aus beiden Werten charakterisieren. Beanspruchung „zerfällt" in der Regel noch in je einen Faktor für „sozial-emotionale Beanspruchung" und „leistungsbezogene Beanspruchung".

Exkurs

Die Merkmalsstruktur stellt ein lineares Strukturgleichungsmodell anschaulich und präzise dar (Abbildung 3). Dabei wird oft zwischen Messmodell (in Abbildung 2 für „Allgemeine Beanspruchung") und dem Strukturmodell für den Merkmalsbereich unterschieden. Strukturgleichungsmodelle zeigen Hinweise auf Verletzungen der Annahme der Klassischen Testtheorie in Form von Messfehlerkorrelationen (siehe dazu auch Wagner, Jiménez, Kallus & Kellmann, 2016).

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

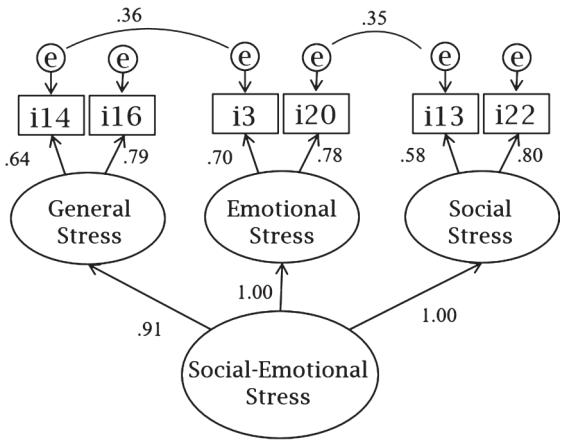

Abbildung 3: Messmodell für „sozial-emotionale Beanspruchung" (Kallus, 2016, S. 68)

Wie am Beispiel des EBF aufgezeigt wurde, lassen sich hoch korrelierende Subtests in vielen Fällen zu Bereichssubtests für den Merkmalsbereich oder für latente Variablen eines psychologischen Konzepts zusammenfassen. In älteren Arbeiten wurde statt des Begriffs der latenten Variablen auch der Begriff der (latenten) Dimension verwendet, um ein psychologisches Konzept wie z. B. Stress theoretisch zu beschreiben. Wenn alle Subtests hoch korrelieren, ergibt sich bei der Faktorenanalyse ein „Generalfaktor" (der den Großteil der Varianz auf sich „vereint"). In diesem Fall ist ein einziger Gesamtwert sinnvoll. Ein solcher Gesamtwert ergibt sich z. B. für den Teamqualitätsfragebogen (Kallus & Brandt, 2006), da hier alle Subtests hoch korrelieren.

Die Güte von Subtests, von Bereichssubtests und von einem Gesamtwert lassen sich mit den Methoden der Klassischen Testtheorie überprüfen, wobei in der Analyse in der Regel die Items auch für die Gesamtwerte und die Bereichssubtests als Dateneinheiten verwendet werden. Der Einsatz der Faktorenanalyse und linearer Strukturgleichungsmodelle in der Fragebogenkonstruktion wird in Kapitel 6.4 aufgegriffen. Die Statistik der Fragebogenentwicklung steht jedoch hinter der Entwicklung eines inhaltlich und theoretisch fundierten Systems von angemessenen Fragen zurück.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

2 Ansätze zur Präzisierung und Operationalisierung des zu erfassenden Merkmalsbereiches

Bei einem psychometrischen Test werden die Items in mehreren Schritten systematisch entwickelt und zusammengestellt. Ergebnis ist ein Fragebogen mit Subtests, der quantitative Aussagen in zuverlässiger Form erlaubt. Eine einfache, oft unsystematische Zusammenstellung von Fragen zu einem Thema gehört im Vergleich dazu eher in den Bereich der qualitativen Forschung. Bei der qualitativen Interpretation von Antworten zu einem Item ist hohe Vorsicht geboten. Hierbei werden messtheoretische Probleme in vielen Fällen sträflich missachtet. Fehlinterpretationen werden oft nicht erkannt und können bis zur politischen Ebene zu Fehleinschätzungen und Fehlentscheidungen führen. In Kapitel 3.4 wird das Skalierungsproblem ausführlich besprochen.

Auf Basis einer klaren Definition und Operationalisierung des zu messenden Konzepts oder Merkmals lassen sich die Frage-Antwort-Komplexe (Items) in angemessener Weise so formulieren, dass die angezielten zuverlässigen Subtestwerte als Resultat der Fragebogenentwicklung tatsächlich sinnvolle Messwerte erbringen. In vielen Fällen sind vorab entsprechende theoretische Vorarbeiten und empirisch orientierte Entwicklungsschritte vorzunehmen.

Im Folgenden wird ein Spektrum von Ansätzen zur Operationalisierung des Merkmalsbereiches zusammenfassend vorgestellt. Dabei werden die Methoden nach steigender Komplexität geordnet. In allen Fällen sind die zu erfassenden Merkmale mindestens mit einer „Arbeitsdefinition" hinreichend klar zu umreißen. Arbeitsdefinitionen sollten mit den wichtigsten Normen und etablierten wissenschaftlichen Festlegungen kompatibel sein oder mindestens dort eingeordnet werden können. In diesem Sinne ist es z. B. wenig sinnvoll, Belastung und Beanspruchung abweichend von der ISO 10075 zu definieren. Schwierig scheint die Definition und Einordnung vor allem bei inflationär verwendeten Begriffen wie Stress, Burnout oder Resilienz. Im Hinblick auf eine sinnvolle Testentwicklung sollte sich die Definition an etablierten theoretischen Konzepten orientieren. Unter Umständen kann an dieser Stelle die Neuentwicklung eines Verfahrens enden, da bereits hinreichend gute Messinstrumente von den verschiedenen wissenschaftlichen Arbeitsgruppen entwickelt wurden. Die vorhandenen Tests können **nach Rücksprache mit den InhaberInnen des Urheberrechts** für die eigene Entwicklung/Befragung ganz oder teilweise übernommen/übersetzt oder adaptiert werden.

In diesem Kapitel werden die folgenden möglichen Ansätze zur Testentwicklung behandelt:

1. Adaptierung – Übersetzung – Neukomposition vorhandener Messinstrumente
2. Konzeptgeleitete Zusammenstellung von Subtests und Items

3. Interviews zur Präzisierung des Merkmalsbereiches
4. Workshop-Methoden
5. Empirisch basierte Konzeptdefinition

2.1 Adaptierung – Übersetzung – Neukomposition vorhandener Messinstrumente

Im einfachsten Fall liegt bei einer Testentwicklung für den relevanten Teil der zu messenden Merkmale bereits ein Fragebogenverfahren vor, möglicherweise jedoch in einer nicht direkt einsetzbaren Sprache. Sollte ein Testverfahren in einer Fremdsprache vorliegen, lässt sich nach Rücksprache mit den AutorInnen in der Regel über eine Übersetzung und/oder Adaptierung auf dem schnellsten Weg ein „neuer" Fragebogen „entwickeln".

2.1.1 Adaptierung – Übersetzung

Bei der Übersetzung und Adaptierung von Items in eine andere Sprache gelten dieselben Leitlinien zur Formulierung von Items wie bei einer Neuentwicklung (vgl. Kapitel 3.3). Die Zusammenstellung von Subtests, die Itemreihenfolgen und die formale Vorgabe müssen sich eng am Originalfragebogen orientieren.

Um die Qualität einer Übersetzung zu prüfen, empfiehlt sich bei Fragebogen eine Rückübersetzung durch eine unabhängige Person, die den Originaltest nicht kennt (Tanzer & Sim, 1999). Diskrepanzen in einer **Übersetzung** können unter anderem auf Übersetzungsfehlern beruhen oder kulturelle Besonderheiten widerspiegeln. Bei Diskrepanzen sollte unter Einbeziehung von „Native Speakern" das Problem aufgedeckt werden und eine **sinngemäß** adäquate Übertragung des Items vorgenommen werden. An dieser Stelle ist es wichtig, das Item vollständig, d. h. Frage- und Antwortoptionen, in die Betrachtung einzubeziehen und auch die anderen Items des Subtests zu betrachten.

Bei der Übertragung eines Fragebogens in eine andere Sprache dürfen formale Kennzeichen nur dann verändert werden, wenn mit dem Sprachwechsel formale Änderungen zwingend sind, wie beim Wechsel von der lateinischen Schriftart auf Kyrillisch oder Griechisch. Die formalen Aspekte betreffen unter anderem Schrifttyp, Schriftgröße, Itemreihenfolge, Anzahl der Items pro Seite, Anordnung der Antwortskalen, Instruktionen, Beispiele etc.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

2.1.2 Übernahme von Subtests und Items bei der Neukonzeption eines Fragebogens

In vielen Projekten ergibt sich durch die Fragestellung oder die Operationalisierung der zu messenden Merkmale eine teilweise inhaltliche Überlappung oder Überschneidung mit bereits vorliegenden Fragebogenverfahren. In diesem Fall ist die einfache Übersetzung oder der Einsatz eines vorliegenden Instruments nicht ausreichend, sondern die vorliegenden Verfahren müssen ergänzt oder neu konzipiert werden. Relativ unproblematisch ist meist die **Kombination** neuer Teilbereiche mit bestehenden Fragebogen oder Subtests anderer AutorInnen. Wichtig bei diesem Vorgehen wie auch bei den im Folgenden besprochenen Vorgehensweisen ist neben einer korrekten Angabe der Quellen eine Rücksprache mit den AutorInnen. Mögliche Verletzungen des Copyrights sind ebenso zu beachten wie wirtschaftliche Schäden durch Plagiate.

Bei der **Übernahme von Subtests** aus vorhandenen Verfahren sind Änderungen und Adaptierungen nur mit größter Behutsamkeit und immer nur in Absprache mit den AutorInnen der Originalversionen vorzunehmen. Änderungen in der Anzahl der Items für Subtests sind in der Regel nach Rücksprache mit den AutorInnen der Originaltests problemlos vorzunehmen. Zur Durchführung der Änderungen lassen sich Informationen aus den Manualen oder den Publikationen zu psychometrischen Kennwerten wie Schwierigkeit, Streuung und Trennschärfe heranziehen. Einschneidende Änderungen sind jedoch zu vermeiden, insbesondere wenn die Änderung den Antwortmodus im Hinblick auf die Anzahl der Stufen oder gar Skalierungsdimension betrifft. Diese Art der Änderung macht eine psychometrische Überprüfung und/oder vollständige Neuentwicklung notwendig.

Auch wenn Items aus bestehenden Verfahren an einen neuen Antwortmodus angepasst und reformuliert werden, sollten die Quellen stets angemessen zitiert werden. Bei der Fragebogenentwicklung ist eine Dokumentation über die „Herkunft“ der Items ein theoretisch, praktisch und juristisch notwendiger und normativ wertvoller Schritt.

2.2 Konzeptgeleitete Zusammenstellung von Subtests und Items

Items sollten wo immer möglich theoriegeleitet anhand vorliegender Modelle, Konzepte oder Taxonomien erstellt werden. Dies ist im Bereich der Wissenschaft unerlässlich. Der Abgleich der Items und Subtests mit vorliegenden Modellen, Konzepten und Theorien kennzeichnet hochwertige Fragebogen auch bei den weiter unten beschriebenen Optionen zur Entwicklung des Itempools. Bei der theoriegeleiteten Formulierung von Items wird entweder ein Modell als Grundlage ausgewählt oder es werden mehrere verwandte Konzepte herangezogen. Zu den in der Theorie dargestellten Facetten werden Items gebildet, die möglichst repräsentativ die Facetten im Verhalten

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

und Erleben von Personen abbilden können. Für jede Facette werden mindestens sechs bis acht Items für einen potenziellen Subtest formuliert. Die Formulierung von Items orientiert sich immer konkret an der Perspektive der Antwortenden. Items können auch dann theoretischen Konzepten folgen, wenn sie konkret formuliert sind. Theoretisch formulierte Items sind typische „Anfängerfehler". Die Frage „Sind Sie bei Ihrer Arbeit primär erfolgsmotiviert?" (ja/nein) sollte besser lauten „Lob spornt mich besonders an" (ja/nein). Es hat sich besonders bewährt, die Merkmalsbereiche möglichst konkret auf der Verhaltens- und Erlebensebene oder durch Beschreibung konkreter Situationen oder Zustände aus dem Merkmalsbereich abzubilden.

Das theoriegeleitete Vorgehen bei der Zusammenstellung von Subtests/Items sei am Beispiel des Erholungs-Belastungs-Fragebogens (EBF; Kallus, 1995) kurz dargestellt. Der Beanspruchungsbereich wurde ausgehend von der Taxonomie für Stressoren bei Janke (1976) in die Bereiche „äußere Belastungen", „Belastungen durch Deprivation primärer Bedürfnisse wie Schlaf", „Leistungsüber/-unterforderungen", „soziale Belastungen" und „sonstige Belastungsfaktoren wie Konflikte und Ungewissheit" gegliedert. Für jede Facette wurden anschließend mindestens acht Items formuliert. Zuvor war festgelegt, dass sich der aktuelle Beanspruchungszustand aus der Häufigkeit von Belastungen „in den letzten Tagen" ergeben sollte. Als Annahme galt zudem, dass sich besonders intensive Stressereignisse in vielen Teilbereichen niederschlagen und sich intensive Belastungen daher auch in Häufigkeitsangaben relativ gut abbilden lassen. Ergänzend wurde die Annahme einbezogen, dass Belastungen dann besonders bedeutsam für den Beanspruchungszustand einer Person sind, wenn nur unzureichende Möglichkeiten zur Regeneration der Ressourcen vorliegen. Initial stand der Versuch, die Erholungsbereiche komplementär zu den Belastungsbereichen in Items abzubilden.

Während sich für den Beanspruchungsbereich die theoretisch abgeleiteten Belastungsdimensionen weitestgehend abbilden ließen, konnten aufgrund hoher Überlappung der Merkmalsbereiche nur einige korrespondierende Regenerationsbereiche abgebildet werden. Interessanterweise konnten, passend zu kognitiven Stressmodellen (z. B. Lazarus, 1966, 1991), überwiegend positiv bewertete Ereignisse und Zustände als „gute Items" für Erholung in die Endform des Erholungs-Belastungs-Fragebogens übernommen werden.

Weitere Beispiele für eine theoriegeleitete Entwicklung von Itempools finden sich im Instrument zur Erfassung der Konflikteskalation am Arbeitsplatz (IKEAr; Kolodej, Voutsinas, Jiménez & Kallus, 2005), im EBF-Sport (Kellmann & Kallus, 2000, 2016), im Test zur Erfassung des Mobbingrisikos am Arbeitsplatz (TEMA; Kolodej, Essler & Kallus, 2010), in der Profilanalyse zur Arbeitszufriedenheit (PAZ; Jiménez, 2008) und auch in einer Vielzahl von Verfahren anderer Arbeitsgruppen, wie dem bereits erwähnten arbeitsanalytischen Fragebogen (ISTA; Semmer, Zapf & Dunckel, 1999), im Trierer Inventar zu chronischem Stress (TICS; Schulz, Schlotz & Becker, 2004) oder beim Verfahren zu Beanspruchungsmessung bei der Arbeit (BMS; Debitz, Plath &

Richter, 2016). Bögel und Rosenstiel (1997) empfehlen auch für MitarbeiterInnenbefragungen ein stärker theoriegeleitetes Vorgehen.

Eine theoretische Konzeption zur „Messung" der Facetten eines hypothetischen Konstrukts oder eines hinreichend klar operationalisierten Merkmals stellt die **Generalisierbarkeitstheorie** (Cronbach, Gleser, Nanda & Rajaratnam, 1972) dar. Danach sollten Items in einem Fragebogen möglichst in „paralleler" Form Informationen zur Ausprägung einer Facette des Merkmals erfassen. Mehrere dieser Items lassen sich dann zusammenfassen und spiegeln Unterschiede zwischen Personen in der Facette wider. Die Generalisierbarkeitstheorie betont auch die Bedeutung von Situationen, in denen sich das relevante Merkmal widerspiegeln sollte. **Situationen** sollten bei der Itemzusammenstellung nicht unbeachtet bleiben. Wenn möglich, sollte die jeweils relevante Situation für die Formulierung der Frage berücksichtigt werden. Die Berücksichtigung von Situationen stößt an Grenzen, weil gerade Situationen oft spezifisch oder typisch für bestimmte Bevölkerungs- oder Berufsgruppen sind. Dadurch ergibt sich der unerwünschte Fall, dass der Einsatzbereich eines Fragebogens dann auf spezifische Gruppen einzugrenzen ist oder dass hypothetische Situationen einzubeziehen sind. Hypothetische Situationen erhöhen die Komplexität von Fragen und müssen sehr geschickt formuliert werden, damit alle Antwortenden eine angemessene Vorstellung entwickeln können. Aufgrund dieser Schwierigkeiten reduzieren hypothetische Situationen oft die Qualität des Fragebogens (vgl. Faulbaum, Prüfer & Rexroth, 2009; Porst, 2009). **Reaktionen** auf hypothetische Situationen lassen sich allerdings nicht ohne Weiteres mit realen Verhaltensweisen und solchen in realen Situationen „mischen".

Wichtig ist die Generalisierbarkeitstheorie für die Entwicklung von Fragebogen insoweit, als ein Item als Beispiel für eines von vielen möglichen Items betrachtet wird und als solches eine Stichprobe aus dem zu messenden Merkmal darstellt. Daher kann bei einer Prüfung des eigenen Itempools die aus der Generalisierbarkeitstheorie ableitbare Frage „Ist dieses Item typisch für das zu messende Merkmal?" eine wesentliche Hilfe darstellen. Bei der Itementwicklung sollten nach der Generalisierbarkeitstheorie die TestentwicklerInnen für jeden Subtest ein Bild der möglichen Items vor Augen haben und aus den „möglichen" Items einige „günstige", am besten „repräsentative" Items auswählen. Dabei ist eine ähnliche Varianz für unterschiedliche Facetten (Subtests) anzustreben, wenn die Items (wie im Regelfall) zu einem ungewichteten Mittelwert (oder einer ungewichteten Summe) zusammengefasst werden sollen.

Wenn möglich, sollte zudem ein Pretest an einer größeren Stichprobe durchgeführt werden. Dieser Pretest erlaubt ($n \geq 50$) eine erste Einschätzung der psychometrischen Eigenschaften und eine Identifikation von „Ausreißeritems". Ausreißeritems entstehen durch unerwartete Varianzeinschränkung und z. B. durch missverständliche (mehrdeutige) Formulierung der Iteminhalte, die nicht von der gesamten Stichprobe als Merkmal der zu messenden Facette verstanden werden. Beispiel: Die Selbstbeschreibung mit der Ausprägung von „gar nicht" bis „sehr stark" zu dem Zustand „dösig"

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.

wird in Deutschland oberhalb der Main-Linie im Sinne eines Desaktivierungszustandes verstanden. Südlich der Main-Linie ist das Item z. T. „unverständlich".

Pilotstudien erlauben Schätzungen zur Reliabilität und damit die Schätzung einer sinnvollen Itemzahl für jeden Subtest bzw. jede Merkmalsfacette. Inhaltlich inhomogene Facetten sollten durch mehr Items abgebildet werden, um eine hinreichende „gemeinsame" Varianz zu erhalten.

Zentral für die Testentwicklung ist zudem, dass Items als **Frage-Antwort-Einheiten** auch in Bezug auf ihre sprachlich-grammatikalische Struktur, das Rating-Format und die Wortwahl **als Stichprobe aus einem Pool** möglicher ähnlicher Items gedacht werden. Items mit ähnlichem Inhalt, aber geändertem Antwortformat oder geänderter grammatikalischer Struktur gehören nicht zwingend in dieselbe Gruppe.

Ein wichtiges Beispiel betrifft die mit Negationen formulierten Items. Sprachliche Negationen stellen keine „einfache" logische Umkehrung dar und sind daher nicht geeignet, Antworttendenzen wie die Tendenz zur Zustimmung abzufangen. Bei einfachen Aussagen wie „Ich mag Skifahren" („gar nicht" … „sehr stark") und „Ich mag Skifahren nicht" („gar nicht" … „sehr stark") wird die Problematik der Negation bereits deutlich. Der Satz „Ich mag Skifahren nicht" mit der Antwort „gar nicht" stellt keine angemessene Reformulierung zu „Ich mag Skifahren sehr" dar. Die Diskussionen über Arbeitszufriedenheit und -unzufriedenheit als zwei relativ unabhängige Dimensionen (Herzberg, 1966) zeigen auf, dass Zufriedenheit und die sprachliche Negation Unzufriedenheit psychologisch kein bipolares Konstrukt darstellen. Interessanterweise zeigen Analysen von Fragebogen in linearen Strukturmodellen immer wieder, dass positiv und negativ formulierte Items dazu tendieren, eigene Faktoren zu bilden (Eid & Schmidt, 2014). Ein empirisches Beispiel dazu liefert die aktuelle Diskussion zur Frage „Engagement als Gegenpol von Burnout" (Maslach & Leiter, 2008). Mit den methodischen Problemen bei der Messung von bipolaren Merkmalen haben sich z. B. Marsh (1996) und Dunbar, Ford, Hunt und Der (2000) auseinandergesetzt. Auch hier ergibt sich für die negativ formulierten Items ein eigener Faktor. Insbesondere Häufigkeitsskalen tendieren dazu, „scheinbare" Bipolaritäten aufzulösen. Beanspruchung und Erholung können innerhalb eines Tages „gemeinsam" variieren. Bestimmte Sportaktivitäten können sogar gleichzeitig (körperlich) hoch beanspruchend und psychisch-emotional extrem erholsam sein.

2.3 Interviews zur Präzisierung des Merkmalsbereiches

Als klassische Ansätze zur Präzisierung von Merkmalsbereichen haben sich neben der Operationalisierung, die auf theoretischen Modellen basiert, eine ExpertInnenbefragung mittels Interview oder die Strukturierung des Problemfeldes durch Interviewstudien etabliert.

Dieses Dokument wurde mit IP-Adresse 134.95.52.226 aus dem Netz der USEB UB Köln am 16.03.2018 um 15:26 Uhr heruntergeladen. Das Weitergeben und Kopieren dieses Dokuments ist nicht zulässig.